


به نام خدا



دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده برق

درس مبانی سیستم‌های هوشمند

مینی پروژه ۱۵

نام: سید محمد رضا حسینی

شماره دانشجویی: 40117463

لینک گیت هاب:

<https://github.com/isrezahosseini-cell/Fundamentals-of-Intelligent-Systems/tree/main>

سوال اول:

الف:

Sensitivity (True Positive Rate)

$$\text{Sensitivity} = \text{TP} / (\text{TP} + \text{FN})$$

Specificity (True Negative Rate)

$$\text{Specificity} = \text{TN} / (\text{TN} + \text{FP})$$

ب:

برای کلاس C1 :

$$\text{TP}=45, \text{FN}=6, \text{FP}=5, \text{TN}=90;$$

$$\text{Sensitivity} = 45 / (45 + 6) = 0.88;$$

$$\text{Specificity} = 90 / (90 + 5) = 0.95;$$

برای کلاس C2 :

$$\text{TP}=32, \text{FN}=11, \text{FP}=7, \text{TN}=96;$$

$$\text{Sensitivity} = 32 / (32 + 11) = 0.74;$$

$$\text{Specificity} = 96 / (96 + 7) = 0.93;$$

برای کلاس C3 :

$TP=16, FN=16, FP=4, TN=112;$

$Sensitivity=16/16+14=0.53;$

$Specificity=112/112+4=0.97;$

برای کلاس C4 :

$TP=20, FN=2, FP=17, TN=107;$

$Sensitivity=20/20+2=0.91;$

$Specificity=107/107+17=0.86;$

سوال اول:

$$Y=+1 : (1, 1), (0, 2), (3, 0);$$

لیبل گذاری:

$$Y=-1 : (-2, -1), (0, -2);$$

$$W^0 = (0, 0);$$

ماتریس وزن:

$$b^0 = 0;$$

ماتریس بایاس:

$$y_i(W^T x_i + b) \leq 0$$

شرط فعال شدن یادگیری:

$$\eta = 1;$$

نرخ یادگیری:

$$W^{(k+1)} = W^k + \eta \cdot Y_i x_i$$

بروزرسانی وزن ها:

$$b^{(k+1)} = b^k + \eta \cdot Y_i$$

بروزرسانی بایاس:

$$x_1 = (1, 1), Y_1 = 1;$$

نمونه اول:

$$W^{(0)T}x_1 + b^{(0)} = (0)(1) + (0)(1) + 0 = 0;$$

شرط خطا برقرار است.


$$W^{(1)} = W^{(0)} + 1 \cdot (1) \cdot (1, 1) = (0, 0) + (1, 1) = (1, 1);$$

$$b^{(1)} = b^{(0)} + 1 \cdot (1) = 0 + 1 = 1;$$

نمونه‌های دیگر احتیاجی به بروزرسانی نخواهند داشت دیگر. (زیرا شرط برای آنها فعال

نخواهد شد.)

بررسی جواب کد بدست آمده با استفاده از پایتون:



الف:

لیبل گذاری: $Y=+1 : (1, 1, 1), (0, 2, 1), (3, 0, 1);$

$Y=-1 : (-2, -1, 1), (0, -2, 1);$

ماتریس وزن: $W^0 = (0, 0, 0);$

شرط فعال شدن یادگیری: $y_i(W^T x_i) \leq 0$

نرخ یادگیری: $\eta = 1;$

بروزرسانی وزن ها: $W^{(k+1)} = W^k + \eta \cdot Y_i x_i$

آغاز بروزرسانی:

نمونه اول: $x_1 = (1, 1, 1), Y_1 = 1;$

$$W^{(0)T} x_1 = (0)(1) + (0)(1) + 0 = 0;$$

شرط خطا برقرار است.

$$W^{(1)} = (1, 1, 1)$$

نمونه‌های دیگر احتیاجی به بروزرسانی نخواهند داشت دیگر. (زیرا شرط برای آنها فعال نخواهد شد).

به همان نتیجه قبل رسیدیم.

ب:

تشکیل ماتریس ویژگی‌ها:


$$y = \begin{pmatrix} 1 \\ 1 \\ 1 \\ -1 \\ -1 \end{pmatrix} Z = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 2 & 1 \\ 3 & 0 & 1 \\ -2 & -1 & 1 \\ 0 & -2 & 1 \end{pmatrix}$$

$$W = (Z^T Z)^{-1} Z^T Y$$

معادله خط بدست آمده:

$$0.3089x_1 + 0.5073x_2 + 0.0764 = 0$$

The line $0.3089x_1 + 0.5073x_2 + 0.0764 = 0$ and the line $x_1 + x_2 + 1 = 0$



همانطور که پیداست معادلات خطها مشابه نیستند.

پ:

$$W = S_W^{-1}(\mu_1 - \mu_2)$$

$$\mu_1 = \frac{1}{3} \begin{pmatrix} 4 \\ 3 \end{pmatrix}; \quad \mu_2 = \frac{1}{2} \begin{pmatrix} -2 \\ -3 \end{pmatrix}$$

$$S_W = S_1 S_2$$

$$S_k = \sum (x - \mu_k)(x - \mu_k)^T$$

$$S_1 = \begin{pmatrix} \frac{14}{3} & -3 \\ -3 & 2 \end{pmatrix}; S_2 = \begin{pmatrix} 2 & -1 \\ -1 & \frac{1}{2} \end{pmatrix};$$

$$S_W = \begin{pmatrix} \frac{20}{3} & -4 \\ -4 & \frac{5}{2} \end{pmatrix}; S_W^{-1} = \begin{pmatrix} \frac{15}{4} & 6 \\ 6 & 10 \end{pmatrix};$$


$$W = (23.75, 39)^T;$$

$$\mu_{mid} \begin{pmatrix} 1 \\ \frac{6}{-1} \\ \frac{-1}{4} \end{pmatrix}$$

$$B = -W^T \mu_{mid} = 5.79$$

$$\text{FLD: } 23.75x_1 + 39x_2 + 5.79 = 0$$

The line $0.3089x_1 + 0.5073x_2 + 0.0764 = 0$ and the line $x_1 + x_2 + 1 = 0$ and $23.75x_1 + 39x_2 + 5.79 = 0$



همانطور که از شکل هم پیداست دو روش آخر تقریباً یک معادله خط رو بدست آوردن. ماتریس های ضرایب ان ها در یک راستا قرار دارند.

روش	بردار وزن اصلی (w_1, w_2)	نسبت w_2/w_1	جهت تقریبی (شیب خط جداکننده)
کمترین مربعات (LS)	$(\frac{190}{615}, \frac{312}{615}) \approx (0.3089, 0.5073)$	$\frac{0.5073}{0.3089} \approx 1.642$	شیب خط: $-\frac{w_1}{w_2} \approx -0.602$
فیشر (FLD)	$(\frac{95}{4}, 39) = (23.75, 39)$	$\frac{39}{23.75} \approx 1.642$	شیب خط: $-\frac{w_1}{w_2} \approx -0.609$

لینک کولب سوال دوم:

<https://colab.research.google.com/drive/1gyjc7O9telHdHyHTiPeCz2A2JYM81iYJ?usp=sharing>

اگر PCA مستقیماً و بدون مقیاس‌گذاری بر روی این داده‌ها اعمال شود، ویژگی x_1 با دامنه بزرگتر، مولفه‌های اصلی را تحت تاثیر خود قرار می‌دهد و جواب ما اعتباری ندارد.

1-PCA بر اساس تجزیه مقدار ویژه ماتریس کوواریانس داده‌ها کار می‌کند.

ماتریس کوواریانس: عناصر روی قطر اصلی نشان دهنده واریانس هر ویژگی هستند.

تاثیر دامنه: واریانس یک ویژگی تقریباً متناسب با مربع دامنه آن است. از آنجایی که

دامنه x_1 تقریباً 1000 و دامنه x_2 تقریباً 1 است: $\text{var}(x_1) \gg \text{var}(x_2)$

مقادیر ویژه: مقادیر ویژه نشان دهنده میزان واریانس توضیح شده توسط هر

مولفه اصلی هستند.

همچنین بزرگترین مقدار ویژه تقریباً واریانس x_1 را منعکس می‌کند.

نتیجه تأثیر: اولین مؤلفه اصلی PC_1 تقریباً تمام واریانس داده‌ها را در جهت x_1

جذب می‌کند و PCA به درستی رفتار نمی‌کند. به جای یافتن جهت بهینه که

بیشترین اطلاعات هر دو ویژگی را حفظ کند، فقط جهت ویژگی با واریانس بالاتر را به

عنوان مؤلفه اصلی انتخاب می‌کند.

-2

ویژگی غالب x_1 :

دلیل:

همانطور که در بخش قبل توضیح داده شد، PCA به دنبال جهتی است که بیشترین واریانس را در داده‌ها داشته باشد. به دلیل تفاوت فاحش در دامنه‌ها $\text{var}(x_1)$ چندین مرتبه بزرگتر از $\text{var}(x_2)$ است.

- مؤلفه اصلی اول: PC1 بردار ویژه مربوط به بزرگترین مقدار ویژه خواهد بود. این بردار تقریباً به طور کامل در جهت محور x_1 قرار می‌گیرد.
- به عبارت دیگر، ضریب وزن‌دهی ویژگی x_1 در مؤلفه اصلی اول، بسیار بزرگتر از ضریب x_2 خواهد بود.

این باعث می‌شود که PC1 به جای نمایش یک ترکیب بهینه واریانس هر دو ویژگی، عملاً همان ویژگی x_1 باشد، و نقش x_2 (علیرغم اینکه ممکن است حاوی اطلاعات مهمی باشد) نادیده گرفته شود.

1. استانداردسازی (Standardization / Z-Score Scaling)

مرحله: برای هر ویژگی x_j ، میانگین (μ_j) را کم و بر انحراف معیار (σ_j) تقسیم می‌کنیم.

$$x'_j = \frac{x_j - \mu_j}{\sigma_j}$$

دلیل: استانداردسازی تضمین می‌کند که پس از پیش‌پردازش، میانگین هر ویژگی برابر با صفر و واریانس هر ویژگی برابر با یک شود. در این حالت، ماتریس کوواریانس تبدیل به ماتریس همبستگی می‌شود.

با برابری واریانس‌ها، PCA به جای واریانس خام، همبستگی‌های واقعی بین ویژگی‌ها را تحلیل می‌کند و بردار مؤلفه اصلی به درستی جهت بیشترین تغییر (در فضای مقیاس‌گذاری شده) را پیدا می‌کند.

2. مرکزدهی (Centering)

مرحله: میانگین هر ویژگی را از آن کم می‌کنیم: $x''_j = x_j - \mu_j$

دلیل: مرکزدهی ضروری است تا PCA به جای واریانس کل داده‌ها حول مبدأ، واریانس حول میانگین (مرکز واقعی ابر داده‌ها) را محاسبه کند. این کار همیشه اولین گام ضروری در PCA است. (استانداردسازی شامل مرکزدهی نیز می‌شود).

سوالات 4 و 5 در گوگل کولب نوشته شده اند و لینک آن ها در گیت قرار گرفته.