


به نام خدا



دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده برق

درس مبانی سیستم‌های هوشمند

مینی پروژه 2ه

نام: سید محمد رضا حسینی

شماره دانشجویی: 40117463

لینک گیت هاب:

<https://github.com/isrezahosseini-cell/Fundamentals-of-Intelligent-Systems/tree/main>

پرسش اول)

1. فرم اولیه SVM سخت حاشیه (Primal Form)

هدف: یافتن یک ابر صحنه جداکننده که کلاس‌ها را بطور کامل جدا کند و بیشترین حاشیه را داشته باشد.

$$\text{Minimize: } \frac{1}{2} \|w\|^2$$

تحت محدودیت (constraint):

$$y_i(w \cdot x_i + b) \geq 1, \quad \text{for } i = 1, \dots, n$$

2. اثبات عرض حاشیه هندسی

عرض حاشیه هندسی (Geometric Margin) برابر با $\frac{2}{\|w\|}$ است.

مراحل اثبات

1. خطوط حاشیه: ابرصفحه جداکننده در وسط دو خط حاشیه موازی قرار دارد که بردارهای

پشتیبان (نزدیکترین داده‌ها) روی آن‌ها قرار می‌گیرند. معادلات این خطوط عبارتند از:

$$(y_i = +1 \text{ برای بردارهای پشتیبان با } +1) \quad w \cdot x_+ + b = +1$$

$$(y_i = -1 \text{ برای بردارهای پشتیبان با } -1) \quad w \cdot x_+ + b = -1$$

2. اختلاف برداری: معادلات را از هم کم می‌کنیم (x_+ و x_- بردارهای پشتیبان هستند):

$$(w \cdot x_+) - (w \cdot x_-) = 1 - (-1)$$

$$w \cdot (x_+ - x_-) = 2$$

3. محاسبه فاصله کل (عرض حاشیه): عرض حاشیه d برابر با طول بردار اختلاف $(x_+ - x_-)$ بر روی

بردار واحد عمود بر خطوط، یعنی $\frac{w}{\|w\|}$ ، است.

$$d = \frac{|w \cdot (x_+ - x_-)|}{\|w\|}$$

4. نتیجه نهایی: با چایگزینی $w \cdot (x_+ - x_-) = 2$ ، به نتیجه می‌رسیم:

$$\text{عرض حاشیه} = d = \frac{2}{\|w\|}$$

3. استخراج فرم دوگانه و توجیه بردارهای پشتیبان

الف. استخراج فرم دوگانه (Dual Form)

برای استخراج فرم دوگانه، از ضرب‌کننده‌های لاگرانژ ($a_i \geq 0$) استفاده می‌کنیم.

1. تابع لاگرانژ (Lagrangian):

$$\mathcal{L}(w, b, a) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n a_i [y_i (w \cdot x_i + b) - 1]$$

2. شرط بهینگی (KKT): برای یافتن نقطه زینی (Saddle Point)، \mathcal{L} را نسبت به w و b مشتق می‌گیریم

و بابر صفر قرار می‌دهیم:

مشتق نسبت به w :

$$\frac{\partial \mathcal{L}}{\partial w} = - \sum_{i=1}^n a_i y_i x_i = 0 \Rightarrow w = \sum_{i=1}^n a_i y_i x_i$$

مشتق نسبت به w :

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^n a_i y_i = 0 \Rightarrow \sum_{i=1}^n a_i y_i = 0$$

3. جایگذاری (Dual Formation): مقادیر w و شرط مشتق b را در تابع لاگرانژ اولیه جایگذاری

می‌کنیم. پس از ساده‌سازی، به فرم دوگانه می‌رسیم:

$$\text{Maximize: } \tilde{\mathcal{L}} = (a) = \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_i a_j y_i y_j (x_i \cdot x_j)$$

تحت محدودیت:

$$\sum_{i=1}^n a_i y_i = 0 \text{ and } a_i \geq 0, \text{ for } i = 1, \dots, n$$

ب. دلیل ظهور بردارهای پشتیبان در تابع تصمیم

تابع تصمیم (SVM (Decision Function) برای یک نقطه جدی x_{new} به شکل زیر است:

$$f(x_{new}) = w \cdot x_{new} + b$$

با جایگذاری $w = \sum_{i=1}^n a_i y_i x_i$ در تابع تصمیم:

$$f(x_{new}) = \left(\sum_{i=1}^n a_i y_i x_i \right) \cdot x_{new} + b = \sum_{i=1}^n a_i y_i (x_i \cdot x_{new}) + b$$

دلیل اینکه نمونه‌ها با $a_i > 0$ (بردارهای پشتیبان) در تابع تصمیم ظاهر می‌شوند، شرط مکمل بودن

(Slackness Complementary) از شرایط KKT است:

$$a_i [y_i (w \cdot x_i + b) - 1] = 0$$

این شرط به ما می‌گوید که برای هر نقطه داده i ، دو حالت داریم:

1. نقاط غیرپشتیبان: اگر نقطه‌ای خارج از حاشیه باشد، محدودیت فعال نیست: $y_i(w \cdot x_i + b) > 1$.

برای اینکه شرط KKT برقرار باشد، باید $a_i = 0$ باشد.

2. بردارهای پشتیبان: اگر نقطه‌ای روی مرز حاشیه باشد، محدودیت فعال است: $y_i(w \cdot x_i + b) = 1$.

در این حالت، $a_i > 0$ خواهد بود.

از آنجایی که در فرم نهایی تابع تصمیم، $f(x_{new})$ یک مجموع وزن‌دار است که با a_i ضرب شده است،

فقط نمونه‌هایی که $a_i > 0$ دارند (یعنی بردارهای پشتیبان) در محاسبه نهایی تابع تصمیم مشارکت

می‌کنند و سایر نقاط چون $a_i = 0$ دارند، از این مجموع حذف میشوند.

پرسش دوم)

1. فرم اولیه SVM حاشیه نرم با متغیرهای شل شدگی (ξ_i)

فرم اولیه SVM حاشیه نرم برای مدل‌های خطی غیرقابل تفکیک خطی، با اضافه کردن متغیرهای

شل شدگی (Slack Variables)، $\xi_i \geq 0$ و پارامتر جریمه C ، به صورت زیر تعریف می‌شوند.

هدف (Objective): کمینه‌سازی نرم بردار وزن به همراه جریمه خطی برای هرگونه نقض حاشیه.

$$\text{Minimize: } \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

تحت محدودیت (Constraints):

1. محدودیت شل شدگی (Margin Constraint with Slack):

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad \text{for } i = 1, \dots, n$$

2. نامنفی بودن متغیرهای شل شدگی:

$$\xi_i \geq 0, \quad \text{for } i = 1, \dots, n$$

نقش متغیرهای ξ_i

$\xi_i = 0$: داده به درستی طبقه‌بندی شده و خارج یا روی حاشیه قرار دارد (مانند Hard Margin SVM).

$0 < \xi_i < 1$: داده به درستی طبقه‌بندی شده، اما در داخل حاشیه قرار گرفته است (نقض نرم حاشیه).

$\xi_i \geq 1$: داده به اشتباه طبقه‌بندی شده است (در سمت اشتباه ابرصفحه قرار دارد).

2. اثبات تساوی با تابع زیان لولا (Hinge Loss)

فرمول اولیه را می‌توان با کمینه‌سازی تابع زیر دانست، که در آن زیان لولا (Hinge Loss) استفاده شده است.

$$\text{Minimize: } \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i f(x_i))$$

که در آن $f(x_i) = w \cdot x_i + b$

مراحل اثبات:

هدف ما ثابت کردن این است که:

$$\text{Minimize } \left[\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \right]$$

تحت محدودیت $\xi_i \geq 0$ و $\xi_i \geq 1 - y_i f(x_i)$ معادل است با:

$$\text{Minimize } \left[\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i f(x_i)) \right]$$

1. تعریف ξ_i بهینه: متغیرهای شل‌شدگی ξ_i در تابع هدف اولیه (بخش 1) دارای ضریب مثبت C هستند.

بنابراین برای کمینه‌سازی کل عبارت، باید مقادیر ξ_i را تا حد امکان کوچک انتخاب کنیم.

2. شرط بر روی ξ_i : متغیر ξ_i باید همزمان دو شرط را ارضا کند:

شرط اول (از محدودیت): $\xi_i \geq 1 - y_i f(x_i)$

شرط دوم (از تعریف): $\xi_i \geq 0$

3. انتخاب مقدار کمینه: برای کمینه سازی تابع هدف، باید ξ_i را برابر با بیشینه (Maximum) دو مقدار

کران پایین قرار دهیم:

$$\xi_i^* = \max(0, 1 - y_i f(x_i))$$

هر مقدار ξ_i کوچکتر از ξ_i^* ، حداقل یکی از محدودیت ها را نقض می کند.

4. جایگزینی: با جایگزینی مقدار بهینه ξ_i^* در تابع هدف اولیه:

$$\text{Minimize} \left[\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i^* \right]$$

$$\text{Minimize} \left[\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i f(x_i)) \right]$$

این عبارت $\max(0, 1 - y_i f(x_i))$ همان زیان لولا (Hinge Loss) است.

3. تاثیر پارامتر C بر تعمیم پذیری و بردارهای پشتیبان

پارامتر C یک پارامتر تنظیم کننده (Regularization Parameter) است که میزان تعادل بین دو هدف

متضاد در SVM حاشیه نرم کنترل می کند:

بیشینه سازی حاشیه: که با کمینه سازی $\frac{1}{2} \|w\|^2$ کنترل می شود.

کمینه سازی خطای طبقه بندی و نقض حاشیه: که با کمینه سازی $\sum \xi_i$ (زیان لولا) کنترل می شود.

الف. تاثیر بر تعمیم پذیری (Generalization)

C کوچک:

$$\frac{1}{2} \|w\|^2 \text{ (جریمه حاشیه) اهمیت بیشتری داده می شود.}$$

SVM ترجیح می دهد حاشیه بزرگتری را انتخاب کند، حتی اگر تعداد بیشتری از نقاط در داخل حاشیه

قرار گیرند یا اشتباه طبقه بندی شوند (خطای آموزش افزایش یابد).

این مدل ساده تر است (نرم w کوچکتر است) و احتمال بیش برآزش (Overfitting) کاهش میابد.

بنابراین، تعمیم پذیری به طور کلی بهتر است.

C بزرگ:

$$\sum \xi_i \text{ (جریمه خطا) اهمیت بیشتری داده می شود.}$$

SVM تلاش می کند تمام نقاط را به درستی طبقه بندی کرده و نقض حاشیه را به حداقل برساند

(خطای آموزش کمینه می شود).

این مدل ممکن است پیچیده تر شود (نرم w بزرگتر است) و احتمال بیش برآزش افزایش می یابد.

تعمیم پذیری ممکن است کاهش یابد.

ب. تاثیر بر تعداد بردارهای پشتیبان

C کوچک:

مدل انعطاف پذیری بیشتری در نقض حاشیه دارد. بسیاری از نقاط ممکن است در داخل حاشیه قرار

گیرند ($0 < \xi_i < 1$) یا حتی اشتباه طبقه بندی شوند ($\xi_i \geq 1$).

هر نقطه‌ای که $\xi_i < 0$ یا دقیقاً روی مرز حاشیه باشد، بردار پشتیبان محسوب می‌شود.

در نتیجه بردارهای پشتیبان افزایش می‌یابد.

C بزرگ:

مدل جریمه سنگینی را برای نقض حاشیه اعمال می‌کند. فقط نقاطی که عملاً جدایی‌ناپذیرند یا

نزدیکترین نقاط به مرزهای سخت حاشیه هستند، به عنوان بردار پشتیبان باقی می‌مانند.

مدل تلاش می‌کند تا حد ممکنه SVM سخت حاشیه نزدیک شود.

در نتیجه، تعداد بردارهای پشتیبان کاهش می‌یابد. (البته در حالت حدی که $C \rightarrow \infty$ می‌شود، به

مدل سخت حاشیه باز می‌گردیم که تعداد بردارهای پشتیبان می‌تواند زیاد باشد).

به طور خلاصه، C نقش یک پارامتر معاوضه (Trade-off) را دارد: C بزرگ یعنی تأکید بر دقت آموزش (مدل

پیچیده)، و C کوچک یعنی تأکید بر تعمیم‌پذیری (مدل ساده‌تر).

پرسش سوم

الف. فرم اولیه Soft Margin- ℓ_2 SVM

در این مدل، به جای جریمه خطی (نرم ℓ_1) برای متغیرهای شل شدگی ξ_i ، از جریمه مربعی (ℓ_2) استفاده می‌شود.

$$\text{Minimize} \left[\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i^2 \right]$$

تحت محدودیت (Constraints):

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad \text{for } i = 1, \dots, n$$

توجه: برخلاف حالت ℓ_1 ، محدودیت $\xi_i \geq 0$ دیگر ضروری نیست، زیرا جریمه ξ_i^2 همیشه مثبت است و کمینه سازی تضمین می‌کند که ξ_i ها تا حد امکان کوچک و نزدیک به صفر باشند.

ب. دوگان متناظر (Dual Form)

برای استخراج دوگان، از تابع لاگرانژ استفاده می‌کنیم:

$$\mathcal{L}(w, b, \xi, a) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i^2 - \sum_{i=1}^n a_i [y_i(w \cdot x_i + b) - 1 + \xi_i]$$

مشتق نسبت به w و b همانند حالت ℓ_1 است:

$$\frac{\partial \mathcal{L}}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^n a_i y_i x_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \Rightarrow \sum_{i=1}^n a_i y_i = 0$$

مشتق نسبت به ξ_i : این بخش، تفاوت اصلی را ایجاد می‌کند.

$$\frac{\sigma \mathcal{L}}{\sigma \xi_i} = 2C \xi_i - a_i = 0 \Rightarrow \xi_i = \frac{a_i}{2C}$$

با جایگذاری b.w و ξ_i در \mathcal{L} ، فرم دوگانه به دست می‌آید:

$$\text{Maximize: } \tilde{\mathcal{L}}(a) = \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_i a_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^n \frac{a_i^2}{4C}$$

تحت محدودیت:

$$\sum_{i=1}^n a_i y_i = 0 \text{ and } a_i \geq 0, \quad \text{for } i = 1, \dots, n$$

ج. تفاوت کران‌های a_i با حالت ℓ_1 و اثر آن بر SVها

ویژگی	ℓ_1 Soft Margin (جریمه خطی)	ℓ_1 Soft Margin (جریمه مربعی)
کران‌های a_i در دوگان	$0 \leq a_i \leq C$	$0 \leq a_i$ (بدون کران بالایی)
تعداد بردارهای پشتیبان (SV)	a_i ها به C محدود می‌شوند، که اغلب منجر به تعداد کمتری SV می‌شود.	a_i ها کران بالا ندارند، که اغلب منجر به تعداد بیشتری SV (و SVهای با a_i کوچک) می‌شود.
وزن SVهای خارج حاشیه	SVهای خارج حاشیه ($\xi_i \leq 1$) همیشه $a_i = C$ دارند. (نقاط پرت به شدت جریمه و سخت محدود می‌شوند)	SVهای خارج حاشیه ($\xi_i \geq 1$) می‌توانند $a_i > C$ داشته باشند. (نقاط پرت به صورت نرم‌تر و پیوسته‌تر جریمه می‌شوند.)

توضیح اثر بر w (وزن‌ها)

$$w = \sum_{i=1}^n a_i y_i x_i$$

در هر دو حالت،

ℓ_1 : دارای کران سخت $a_i \leq C$ است. این امر باعث می‌شود که یک نقض حاشیه بزرگ (نقاط پرت) فوراً a_i را به C برساند و سهم آن در w محدود باشد. این مدل کمی تنگ‌تر (Sparser) است.

ℓ_2 : کران a_i ندارد. $\xi_i = \frac{a_i}{2C}$. این بدان معناست که a_i می‌تواند بزرگ باشد تا به یک نقطه پرت بزرگ پاسخ دهد. این جریمه پیوسته باعث می‌شود که $SVM - \ell_2$ نسبت به نقاط پرت حساس‌تر باشد و ممکن است w بزرگ‌تر و متراکم‌تری تولید کند.

پرسش چهارم) کرنل و شرایط KKT

الف. تعریف کرنل معتبر و ارتباط با نگاشت ویژگی

کرنل معتبر (Valid Kernel)، که با $K(x_i, x_j)$ نشان داده می‌شود، یک تابع ریاضی است که شرایط خاصی را ارضا می‌کند تا بتواند معادل با ضرب داخلی (Dot Product) در یک فضای ویژگی با بعد بالاتر (احتمالاً بی‌نهایت) باشد.

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$$

$\phi(\cdot)$ نگاشت ویژگی (Feature Mapping) است که بردار ورودی x را از فضای ورودی بعد پایین به یک فضای ویژگی بعد بالاتر \mathcal{H} نگاشت می‌کند: $\phi: \mathcal{X} \rightarrow \mathcal{H}$.

شرط اصلی معتبر بودن (قضیه مرسر - Mercer's Theorem): یک تابع K زمانی یک کرنل معتبر است که ماتریس کرنل $K(x_i, x_j) = K_{ij}$ برای هر مجموعه محدودی از نقاط ورودی، یک ماتریس مثبت نیمه معین (Positive Semi-Definite Matrix) باشد.

ارتباط با نگاشت ویژگی: کرنل معتبر به ما اجازه می‌دهد بدون نیاز به تعریف و محاسبه صریح $\phi(x)$ (که اغلب بسیار پیچیده یا بی‌نهایت بعد است)، ضرب داخلی $\phi(x_i) \cdot \phi(x_j)$ را در فضای بعد بالا محاسبه کنیم. این تکنیک به ترفند کرنل (*Kernel Trick*) معروف است.

ب. خواص کرنل های *RBF* و چند جمله‌ای

کرنل های *RBF* و چند جمله‌ای دو مثال رایج از کرنل معتبر هستند:

کرنل چند جمله‌ای (Polynomial Kernel):

$$K(x_i, x_j) = (x_i \cdot x_j + c)^d$$

خواص بردار (Power Property): اگر k_1 و k_2 کرنل باشند، $K(x_i, x_j) = K_1(x_i \cdot x_j)^d$ نیز کرنل معتبر است ($d \in \mathbb{N}$). این خاصیت تضمین میکند که توان d ام از یک کرنل معتبر (مانند ضرب داخلی ساده)، همچنان یک کرنل معتبر خواهد بود. این کرنل یک نگاشت به یک فضای متناهی را انجام می‌دهد.

کرنل تابع شعاعی (RBF-Radial Basis Function/Gaussian Kernel):

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

خواص جمع و ضرب (Summation and Scaling Property): اگر K_1 کرنل باشد، $\exp(K_1)$ نیز کرنل معتبر است.

کرنل *RBF* بر اساس قضیه تیلور (Taylor Expansion) می‌تواند به عنوان یک ضرب داخلی در یک فضای ویژگی بعد نامتناهی (Infinite-Dimensional) در نظر گرفته شود. این خاصیت به آن اجازه می‌دهد تا مرزهای تصمیم بسیار پیچیده‌ای را مدل کند.

ج. حالات KKT به صورت مرتب و نقش هر حالت

شرایط کروش-کوهن-تاکر (Karush-Kuhn-Tucker-KKT) مجموعه‌ای از شرایط لازم بهینگی (Optimality)

هستند که باید توسط هر جواب بهینه (w^*, b^*) برای یک مسئله بهینه‌سازی مقید محدب (مانند SVM) ارضا شوند.

حالات KKT (برای SVM حاشیه نرم ℓ_1)

توصیف هندسی و نقش	شرط KKT	حالت
بردار وزن‌ها را به صورت ترکیب خطی از نمونه‌ها و ضرب کننده‌های لاگرانژ بیان می‌کند.	$w = \sum_{i=1}^n a_i y_i x_i$	مشتق w
شرط تعادل و تقارن لازم برای قرارگیری ابرصفحه در فضای ویژگی.	$\sum_{i=1}^n a_i y_i = 0$	مشتق b
تعیین کننده نوع داده: اگر $a_i > 0$ باشد، محدودیت فعال است (داده روی مرز یا داخل آن است).	$a_i [y_i f(x_i) - 1 + \xi_i] = 0$	مکمل بودن
کران‌های ضرب کننده‌های لاگرانژ (تنظیم کننده جریمه)	$0 \leq a_i \leq C$	دوگان‌پذیری
تمام نقاط باید به درستی طبقه‌بندی شوند (با لحاظ شل شدگی)	$y_i f(x_i) \geq 1 - \xi_i, \xi_i \geq 0$	اولیه/شل شدگی

نقش هر حالت:

شرایط KKT نقش حیاتی در تشخیص بردارهای پشتیبان و اجرای الگوریتم‌های SVM دارند:

نقاط غیرپشتیبان (Non-SV):

$$y_i f(x_i) = 1 \quad (\text{خارج از حاشیه}) \quad \xi_i = 0$$

از شرط مکمل بودن، چون عبارت داخل براکت مثبت است، باید $a_i = 0$ باشد. این نقاط هیچ تاثیری بر w ندارند.

بردارهای پشتیبان معمولی (SV on Margin):

$$y_i f(x_i) = 1 \quad (\text{دقیقا روی مرز}) \quad \xi_i = 0$$

از شرط مکمل بودن، عبارت داخل براکت صفر است. $0 < a_i < C$.

بردارهای پشتیبان خطا (SV violating Margin):

$$y_i f(x_i) < 1 \text{ (نقض حاشیه یا اشتباه طبقه‌بندی).}$$

از شرط مکمل بودن، a_i باید C باشد. این‌ها بحرانی‌ترین نقاط هستند.

پرسش پنجم)

داده ها

کلاس مثبت ($y_i = +1$): $(2, 0), (3, 0), (2, 1), (2, -1)$

کلاس منفی ($y_i = -1$): $(-2, 0), (-3, 0), (-2, 1), (-2, -1)$

الف. حدس ابر صفحه حداکثر حاشیه و معادله مرز تصمیم

حدس ابر صفحه

با مشاهده نقاط داده، متوجه می شویم که داده ها حول محور y به طور کامل متقارن هستند.

تمام نقاط مثبت در ناحیه $x > 0$ و تمام نقاط منفی در ناحیه $x < 0$ قرار دارند.

فاصله نقاط مثبت از محور y ، حداقل 2 واحد است.

فاصله نقاط منفی از محور y ، حداقل 2 واحد است.

بنابراین، بهترین و متقارن ترین ابر صفحه جداکننده (خط جداکننده در \mathbb{R}^2) باید محور y باشد.

معادله مرز تصمیم (ابر صفحه)

معادله محور y به صورت زیر است:

$$x = 0 \text{ یا } 1.x + 0.y = 0$$

معادله مرز تصمیم:

$$w^T x + b = 0 \Rightarrow x = 0$$

محاسبه دستی ضرایب w و b

معادله ابرصفحه تصمیم ما $x=0$ است، که به این معنی است:

$$w = (w_1, w_2) \text{ و } x = (x_1, x_2)$$

$$w_1 x_1 + w_2 x_2 + b = 0 \Rightarrow 1 \cdot x_1 + 0 \cdot x_2 + 0 = 0$$

پس، ما حدس می‌زنیم:

$$w \propto (1, 0) \text{ و } b = 0$$

حالا باید مقادیر دقیق w و b را طوری تنظیم کنیم که محدودیت سخت حاشیه را برای بردارهای پشتیبان (نقاط روی مرز ± 1) ارضا کنند:

$$y_i(w \cdot x_i + b) = 1$$

شناسایی بردارهای پشتیبان

نزدیکترین نقاط به خط $x=0$ نقاطی هستند که $|x_1|$ کمینه را دارند. این نقاط عبارتند از:

$$x_{SV}^+ = (2, 0), (2, 1), (2, -1): \text{کلاس مثبت:}$$

$$x_{SV}^- = (-2, 0), (-2, 1), (-2, -1): \text{کلاس منفی:}$$

اعمال محدودیت

$$\text{برای کلاس مثبت } y_i = 1, x_i = (2, 0):$$

$$1 \cdot (w_1(2) + w_2(0) + b) = 1 \Rightarrow 2w_1 + b = 1 (*)$$

$$\text{برای کلاس منفی } y_i = -1, x_i = (-2, 0):$$

$$-1. (w_1(-2) + w_2(0) + b) = 1 \Rightarrow 2w_1 - b = 1(**)$$

حل دستگاه معادلات

با جمع (*) و (**):

$$(2w_1 + b) + (2w_1 - b) = 1 + 1$$

$$4w_1 = 2 \Rightarrow w_1 = \frac{1}{2}$$

با قرار دادن $w_1 = \frac{1}{2}$ در (*):

$$2\left(\frac{1}{2}\right) + b = 1 \Rightarrow 1 + b = 1 \Rightarrow b = 0$$

همچنین، چون در حدس اولیه $w \propto (1, 0)$ داشتیم، w_2 باید صفر باشد تا ابرصفحه به مختصه x_2 (محور y) وابسته نباشد:

$$w_2 = 0$$

ضرایب محاسبه شده:

$$w = \left(\frac{1}{2}, 0\right), b = 0$$

ج. بردارهای پشتیبان، معادلات ابرصفحه ± 1 و مقدار حاشیه هندسی

بردارهای پشتیبان (Support Vectors-SVs)

بردارهای پشتیبان، تمام نقاطی هستند که در محاسبه w و b محدودیت را فعال می‌کنند (یعنی روی مرز ± 1 قرار دارند):

$$SV = \{(2, 0), (2, 1), (2, -1), (-2, 0), (-2, 1), (-2, -1)\}$$

معادلات ابر صفحه $w^T x + b = \pm 1$

با استفاده از $w = (\frac{1}{2}, 0)$ و $b = 0$:

$$w^T x + b = \pm 1 \Rightarrow \frac{1}{2}x_1 + 0x_2 + 0 = \pm 1$$

ابر صفحه حاشیه مثبت (+1):

$$\frac{1}{2}x_1 = 1 \Rightarrow x_1 = 2$$

ابر صفحه حاشیه مثبت (-1):

$$\frac{1}{2}x_1 = -1 \Rightarrow x_1 = -2$$

مقدار حاشیه هندسی (Geometric Margin)

حاشیه هندسی برابر است با $\frac{1}{\|w\|}$ ، که فاصله ابر صفحه تصمیم تا نزدیک ترین نقطه است.

$$\|w\| = \sqrt{\left(\frac{1}{2}\right)^2 + 0^2} = \sqrt{\frac{1}{4}} = \frac{1}{2}$$

فاصله تا ابر صفحه تصمیم (حاشیه هندسی):

$$\text{حاشیه هندسی} = \frac{1}{\|w\|} = \frac{1}{1/2} = 2$$

فاصله بین دو ابر صفحه $(\frac{2}{\|w\|})$:

$$\text{عرض حاشیه} = \frac{2}{\|w\|} = \frac{2}{1/2} = 4$$

این مقدار منطقی است، زیرا فاصله بین خط $x_1 = 2$ و $x_1 = -2$ دقیقا 4 واحد است.

پرسش ششم)

الف. پیشنهاد مدل مناسب با استفاده از شبکه‌های عصبی

هدف ما مدل‌سازی مرزهای تصمیم پیچیده و غیرخطی است. برای این منظور، یک شبکه عصبی چندلایه (Multi-Layer-Perceptron MLP) بهترین گزینه را ارائه می‌دهد.

مدل پیشنهادی:

شبکه عصبی چندلایه (MLP): MLP شامل یک لایه ورودی، یک یا چند لایه مخفی، و یک لایه خروجی است.

ساختار پیشنهادی (به عنوان مثال):

لایه ورودی: 2 گره (به ازای مختصات x و y).

لایه مخفی: حداقل دو لایه مخفی با تعداد گره‌های کافی (مثلاً 10 گره در هر لایه) برای یادگیری ویژگی‌های غیر خطی.

توابع فعال‌ساز (Activation Functions) لایه‌های مخفی: برای معرفی خاصیت غیرخطی، باید از توابع فعال‌ساز غیرخطی مانند ReLU (Rectified Linear Unit) یا Sigmoid/tanh استفاده شود.

لایه خروجی: 1 گره (با تابع فعال‌ساز سیگموئید برای طبقه‌بندی دوگانه).

توابع پیشنهادی:

Sigmoid یا ReLU :

Sigmoid: در گذشته رایج بود، اما به دلیل مشکل شیب محوشونده (Vanishing Gradient) در لایه‌های عمیق کمتر استفاده می‌شود.

ReLU: به دلیل سادگی و جلوگیری از مشکل شیب محوشونده، معمولاً انتخاب ارجح در لایه‌های میانی است.

نتیجه: برای طبقه‌بندی این داده‌های غیرخطی، یک MLP با توابع فعال‌ساز ReLU در لایه‌های مخفی مناسب‌ترین انتخاب است.

ب. ضعف سایر مدل‌های شبکه عصبی و عملکرد ضعیف مدل‌های خطی

1. ضعف MLP با توابع فعال‌ساز سراسری (Sigmoid/tanh)

اگرچه MLP به خودی خود می‌تواند مرزهای غیرخطی را مدل کند، استفاده از توابعی مانند Sigmoid یا tanh در لایه‌های مخفی ممکن است در این مسئله خاص (داده‌های خوشه‌ای) به طور موثر عمل نکند.

توابع فعال‌ساز سراسری (Global Activation Functions): توابعی مانند Sigmoid و tanh شیب‌های خود را در نواحی دور از صفر از دست می‌دهند (شیب محوشونده). در یک معماری عمیق، این امر باعث می‌شود یادگیری ویژگی‌ها کند شود.

مشکل کرزهای تصمیم غیر محلی (Non-local Decision Boundaries): توابع فعال‌ساز سراسری به طور ذاتی تمایل به ایجاد مرزهای تصمیم صاف و سراسری دارند. این مسئله باعث می‌شود مدل برای جداکردن چهار ناحیه خوشه‌ای کاملاً مجزا (مانند شکل 5 در سوالات) دچار مشکل شود و ممکن است مرزهای تصمیم، بیش از حد از نقاط آموزش دور شوند. در مقابل، توابعی مانند ReLU یا مدل‌های بر پایه کرنل بهتر می‌توانند رفتار موضعی (Local) داده را حفظ کنند.

2. عملکرد ضعیف مدل‌های خطی در تفکیک خوشه‌های محلی

مدل‌های خطی (مانند SVM خطی یا MLP بدون لایه‌های مخفی غیر خطی) عملکرد بسیار ضعیفی در تفکیک این داده‌ها دارند زیرا:

فرض تفکیک‌پذیری خطی: مدل‌های خطی فرض می‌کنند که می‌توان دو کلاس را با یک خط مستقیم (یا ابر صفحه در ابعاد بالاتر) از هم جدا کرد.

ناتوانی در مدیریت XOR: این مجموعه داده، یک نوع تعمیم‌یافته از مسئله XOR (Exclusive OR) در فضای بعد پایین است. برای طبقه‌بندی یک نقطه جدید در مرکز، خط جداکننده مجبور است یک کلاس (مثلاً ابی) را در دو ناحیه جدا از هم قرار دهد، که توسط یک خط مستقیم امکان‌پذیر نیست.

نیاز به نگاشت به فضای بالاتر: برای تفکیک خطی این خوشه‌ها، داده‌ها ابتدا باید توسط یک نگاشت ویژگی غیرخطی (مانند نگاشت $\phi(x)$ در SVM کرنل یا همان لایه‌های مخفی در MLP) به یک فضای بعد بالاتر نگاشته شوند تا در آنجا به صورت خطی قابل تفکیک باشند. مدل‌های خطی این توانایی را ندارند.

پرسش پیاده سازی RBF

هدف این پرسش، مدل سازی یک سیستم دینامیکی ساده با استفاده از یک شبکه عصبی با تابع شعاعی پایه است. در گام اول با پیاده سازی یک RBFNN استاندارد با ساختاری ایستا شروع می شود (بخش اول) و سپس یک شبکه پیشرفته تر و تطبیقی (بخش دوم) توسعه داده می شود که ساختار خود را بر اساس شبکه M-RAN که در **مقاله** ارائه شده، بهینه سازی می شود.

قسمت اول:

شناسایی سیستم با شبکه عصبی RBF

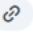


برای این سوال ابتدا یک سیستم ساده شده از نوع ball and beam را مدل سازی می شود. موقعیت توپ در زمان t ، که با $y(t)$ نشان داده می شود، تابعی از دو موقعیت قبلی خود یعنی $y(t-1)$ و $y(t-2)$ و ورودی قبلی به سیستم یعنی $u(t-1)$ است. این رابطه توسط معادله تفاضلی زیر تعریف می شود:

$$y(t) = \frac{y(t-1)}{1 + y(t-2)} + u(t-1)^3$$

گام نخست: ایجاد دیتا ست

پاسخ به بخش ۳.۱.۱: تحلیل مسئله

۱. چرا این مسئله یک مسئله تقریب تابع است؟

- **تعریف مسئله:** مسئله ای که در اینجا تعریف شده، پیش بینی مقدار خروجی $y(t)$ بر اساس یک بردار ورودی معین است:
$$\mathbf{x}(t) = [y(t-1), y(t-2), u(t-1)]^T$$
- وابستگی به فرمول: اگر چه سیستم توسط یک معادله تفاضلی جبری (فرمول ۶۲) تعریف شده است، در حقیقت، شبکه عصبی به فرمول دسترسی ندارد. 
- وظیفه شبکه: وظیفه شبکه عصبی RBFNN این است که یک نگاشت (Mapping) بین فضای ورودی سابعدی $(\mathbf{x}(t))$ و فضای خروجی تک بعدی $(y(t))$ را تخمین بزند.  
- نتیجه: در نهایت، شبکه تلاش می کند تا یک تابع ناشناخته (مجهول) f را بیابد به طوری که $y(t) \approx f(\mathbf{x}(t))$ باشد. از آنجا که هدف تخمین (تقریب) یک تابع $f: \mathbb{R}^3 \rightarrow \mathbb{R}$ از طریق داده های ورودی-خروجی است، این یک مسئله تقریب تابع نامیده می شود. 